

Principal Component Analysis

1. Introduction

Principal Component Analysis (PCA) เป็นวิธีทางสถิติที่ใช้ในการแปลงตัวแปรทางสถิติที่ตั้งฉากกัน (orthogonal) หรือมีความสัมพันธ์กัน (correlated) ให้กลายเป็นตัวแปรที่ไม่สัมพันธ์กัน (uncorrelated)




Figure 1: ลักษณะการแปลงข้อมูลใน PCA

รูปวงรีแทน สมมาตรของวงรีจะเรียกว่า “principal axis” ซึ่งคำว่า principal axis เป็นการเรียกรวมของแกนเอกและแกนโทของวงรี ในกรณีที่เป็นวงรีสองมิติก็จะมีแกน สมมาตร 2 แกน แต่ถ้าอยู่ใน p มิติก็จะมี principal axis p แกน สำหรับข้อมูลที่มีการกระจายตามรูปที่ 1 เราจะกำหนด principal component ด้วยแนวคิดเดียวกันกับ




Figure 2: Principal axis ของวงรี

principal axis ของวงรี แต่เนื่องจากจุดข้อมูลไม่ได้มีแกนเอกแกนโทอย่างชัดเจน principal component จึงหาจากการ maximize variance แทน ซึ่งแกนที่จุดข้อมูลโปรเจกต์ลงมาแล้ว จะให้ค่า variance บนแกนมากที่สุดก็จะเป็น principal component เหมือนกับส่วนที่ป่องที่สุดของวงรีเป็น principal axis

2. Finding Principal Components

ข้อมูลก่อนที่จะนำมาทำ PCA จะอยู่ในรูปของเมทริกซ์ขนาด $n \times p$ โดยที่ n คือจำนวนจุดข้อมูลและ p เป็นจำนวน feature

$$X = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{bmatrix}$$

vector x_1
PCA ==> p มิติ

ก่อนที่จะหา principal component ให้ลบทุกพีเจอร์ตด้วยค่าเฉลี่ยเพื่อเป็นการเลื่อนข้อมูลมาอยู่บริเวณกึ่งกลาง หรือ

standardization เป็นวิธีการพื้นฐานในการทำ feature scaling ==> mean = 0

$$\sum_{i=1}^n x_{i,d} = 0$$

เนื่องจากต้องการกำหนดให้เวกเตอร์ principal component vector มีทิศพุ่งออกจากจุดกำเนิด จึงต้องกำหนดเวกเตอร์หนึ่งหน่วยของ principal component ใน p มิติ ก็จะเขียนได้เป็น

$$\vec{v} = v_1 \mathbf{x}_1 + v_2 \mathbf{x}_2 + \cdots + v_p \mathbf{x}_p$$

linear combination

หรือเขียนเป็นรูปเมทริกซ์ได้ว่า

มิติใหม่ที่เรากำลังจะสร้างคือ vector v

เหตุผลที่ทำให้ variance ของระบบก่อนและหลังทำ PCA เท่าเดิม

1. map ไปสู่มิติใหม่ด้วย linear combination
2. eigenvector (v , แกนใหม่) ที่ออกมามันตั้งฉากกันทั้งหมด
3. $\|v\| = 1$

ค่าของ feature บนมิติใหม่ = dot product ของแกนกับข้อมูล sample นั้น ๆ ที่เราสนใจ

จากนั้นโปรเจกต์เวกเตอร์ของจุดข้อมูลลงบนแกน v จะได้ดังรูป

ถ้าพิจารณาจุด x_i ใดๆ เมื่อโปรเจกต์ลงบนแกน v แล้ว ระยะห่างจากจุดกำเนิดจนถึงจุดที่ข้อมูลถูกโปรเจกต์ก็จะหาได้จาก

$$s_i = \mathbf{v} \cdot \mathbf{x}_i$$

ค่าที่ project ได้แทนด้วยตัวแปร s
ทุก feature ของ sample ที่ i

2

เอาข้อมูลตั้งต้นตัวที่ i ไป project ค่าลงบนแกน v ==> ค่าบนแกน v เป็น s_i





Figure 3: ลักษณะการโปรเจกต์จุดข้อมูลลงบนแกน



$s_1, s_2, s_3, \dots, s_n$
 \Rightarrow ค่าหลังจากถูก map แล้วบนแกน v

Figure 4: วิธีการวัดระยะ s_i

Variance บนแกน v หาได้จาก

$$\frac{\sum (s_i - \bar{s})^2}{n}$$

$$\begin{aligned} \sigma^2 &= \frac{1}{n} \sum_{i=1}^n s_i^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i)^2 \end{aligned}$$

Principal component จะเป็นแกนที่ทำให้เกิด variance มากที่สุด ดังนั้นก็จะได้ว่า

$$\max \sigma^2 = \max \sum_{i=1}^n s_i^2$$

โดยมีเงื่อนไขคือ

$$\|\mathbf{v}\|^2 = 1$$

หรือ

$$v_1^2 + v_2^2 + \dots + v_p^2 = 1$$

ซึ่งเงื่อนไขนี้จะบังคับว่าให้เวกเตอร์ \mathbf{v} เป็นเวกเตอร์หนึ่งหน่วย

สมการตั้งต้น PCA

subject to

$$\max \sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i)^2$$

Lagrange's Multipliers

$$g(\mathbf{v}) = 1 - v_1^2 - v_2^2 - \dots - v_p^2 = 0$$

ชุดสมการนี้สามารถแก้ได้โดยวิธี Lagrange Multiplier ซึ่ง Lagrangian function คือ

$$\begin{aligned} L &= \sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i)^2 + \lambda(1 - \sum_{d=1}^p v_d^2) \\ &= \sum_{i=1}^n (v_1 x_{i,1} + v_2 x_{i,2} + \dots + v_p x_{i,p})^2 + \lambda(1 - v_1^2 - v_2^2 - \dots - v_p^2) \end{aligned}$$

นำ L ไปหาอนุพันธ์ย่อยเทียบกับ v_d

$$0 = \frac{\partial L}{\partial v_d}$$

$$0 = \sum_{i=1}^n 2(v_1 x_{i,1} + v_2 x_{i,2} + \dots + v_p x_{i,p}) x_{i,d} - \lambda 2v_d$$

$$0 = 2 \sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i) x_{i,d} - 2\lambda v_d$$

$$\sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i) x_{i,d} = \lambda v_d$$

จากเทอม $\sum (\mathbf{v} \cdot \mathbf{x}_i) x_{i,d}$ กระจายผลรวมและจัดรูปให้อยู่ในเมทริกซ์

$$\begin{aligned}
\sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i) \mathbf{x}_{i,d} &= (v_1 x_{1,1} + v_2 x_{1,2} + \cdots + v_p x_{1,p}) x_{1,d} \\
&\quad + (v_1 x_{2,1} + v_2 x_{2,2} + \cdots + v_p x_{2,p}) x_{2,d} \\
&\quad + \cdots + (v_1 x_{n,1} + v_2 x_{n,2} + \cdots + v_p x_{n,p}) x_{n,d} \\
&= [x_{1,d} \quad x_{2,d} \quad \cdots \quad x_{n,p}] \begin{bmatrix} v_1 x_{1,1} + v_2 x_{1,2} + \cdots + v_p x_{1,p} \\ v_1 x_{2,1} + v_2 x_{2,2} + \cdots + v_p x_{2,p} \\ \vdots \\ v_1 x_{n,1} + v_2 x_{n,2} + \cdots + v_p x_{n,p} \end{bmatrix} \\
&= [x_{1,d} \quad x_{2,d} \quad \cdots \quad x_{n,p}] \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_p \end{bmatrix}
\end{aligned}$$

ถ้านำมารวมกัน p สมการ

$$\sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i) \mathbf{x}_i = \begin{bmatrix} x_{1,1} & x_{2,1} & \cdots & x_{n,1} \\ x_{1,2} & x_{2,2} & \cdots & x_{n,2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1,p} & x_{2,p} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_p \end{bmatrix}$$

สามารถเขียนได้เป็น

$$\sum_{i=1}^n (\mathbf{v} \cdot \mathbf{x}_i) \mathbf{x}_i = X^T X \mathbf{v}$$

ถ้าจะได้คุณเมทริกซ์ $X^T X$

$$X^T X = \begin{bmatrix} \sum_{i=1}^n (x_{i,1})^2 & \sum_{i=1}^n x_{i,1} x_{i,2} & \cdots & \sum_{i=1}^n x_{i,1} x_{i,p} \\ \sum_{i=1}^n x_{i,2} x_{i,1} & \sum_{i=1}^n (x_{i,2})^2 & \cdots & \sum_{i=1}^n x_{i,2} x_{i,p} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{i,p} x_{i,1} & \sum_{i=1}^n x_{i,p} x_{i,2} & \cdots & \sum_{i=1}^n (x_{i,p})^2 \end{bmatrix}$$

ถ้า Matrix ที่คุณอยู่หน้า eigenvector เป็น symmetric matrix
eigenvector ที่ออกมาจะตั้งฉากกันทั้งหมด

$$= n \begin{bmatrix} \text{COV}_{11} & \text{COV}_{12} & \cdots & \text{COV}_{1p} \\ \text{COV}_{12} & \text{COV}_{22} & \cdots & \text{COV}_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \text{COV}_{p1} & \text{COV}_{p2} & \cdots & \text{COV}_{pp} \end{bmatrix}$$

$X^T X v = \lambda v$

เมื่อ cov_{ij} คือ covariance ของ feature ที่ i กับ j ถ้า $i = j$ ก็จะได้ variance ดังนั้นในแนวทแยงของเมทริกซ์

ริกซ์นี้ก็คือค่าความแปรปรวนของเมทริกซ์ ถ้าให้ Σ เป็น covariance matrix ก็จะได้ว่า $\Sigma = \frac{1}{n} X^T X$ จะได้

ถ้าให้ $S = X^T X$ จะได้

$$\begin{aligned} X^T X v - \lambda v &= 0 \\ (X^T X - \lambda I) v &= 0 \Rightarrow \text{eigenvalue \& eigenvector} \\ (S - \lambda I) v &= 0 \end{aligned}$$

v_1, v_2

ปัญหานี้เป็นปัญหา eigenvalue-eigenvector ซึ่งวิธีแก้จะต้องหา eigenvalue แต่ละตัว และหา eigenvector ที่สอดคล้องกับ eigenvalue ก็จะได้เวกเตอร์ที่เป็น principal component ออกมา ตามจำนวนมิติ

3. Numerical Example

สมมติว่าข้อมูลมี 2 มิติ ดังนี้

$$X = \begin{bmatrix} -2.2 & -1.6 \\ -0.2 & 1.4 \\ 1.8 & 0.4 \\ -0.2 & -0.6 \\ 0.8 & 0.4 \end{bmatrix}$$

ลองหาค่าเฉลี่ยของแต่ละ component

$$\mu_1 = \frac{1}{5} (-2.2 - 0.2 + 1.8 - 0.2 + 0.8) = 0$$

$$\mu_2 = \frac{1}{5} (-1.6 + 1.4 + 0.4 - 0.6 + 0.4) = 0$$

เมื่อนำ X ไปทราานสโพล์และคูณกับ X

$$\begin{aligned}
 S &= X^T X \\
 &= \begin{bmatrix} -2.2 & -0.2 & 1.8 & -0.2 & 0.8 \\ -1.6 & 1.4 & 0.4 & -0.6 & 0.4 \end{bmatrix} \begin{bmatrix} -2.2 & -1.6 \\ -0.2 & 1.4 \\ 1.8 & 0.4 \\ -0.2 & -0.6 \\ 0.8 & 0.4 \end{bmatrix} \\
 &= \begin{bmatrix} 8.8 & 4.4 \\ 4.4 & 5.2 \end{bmatrix}
 \end{aligned}$$

เมทริกซ์ที่ได้มานี้จะเป็นเมทริกซ์จัตุรัสที่มีขนาดเท่ากับจำนวนมิติและเป็นเมทริกซ์สมมาตร จากนั้นนำเมทริกซ์นี้ไปหา eigenvalue ซึ่งจำนวน eigenvalue จะเท่ากับจำนวนมิติ ซึ่งเมทริกซ์นี้เป็นเมทริกซ์ขนาด 2×2 ดังนั้นจะมี eigenvalue อยู่ 2 ตัว จาก

$$|S - \lambda I| = 0$$

เมื่อ λ คือ eigenvalue ดังนั้น

$$\begin{aligned}
 |S - \lambda I| &= 0 \\
 \begin{vmatrix} 8.8 & 4.4 \\ 4.4 & 5.2 \end{vmatrix} &= 0 \\
 (8.8 - \lambda)(5.2 - \lambda) - (4.4)(4.4) &= 0 \\
 \lambda^2 - 14\lambda + 26.4 &= 0
 \end{aligned}$$

เมื่อแก้สมการนี้ จะได้คำตอบสองคำตอบคือ

$$\lambda = \frac{35 - \sqrt{565}}{5}, \frac{35 + \sqrt{565}}{5}$$

หา eigenvector ที่สอดคล้องกับ eigenvector แต่ละตัว จาก

$$(S - \lambda I)\mathbf{v} = 0$$

เมื่อ \hat{v} เป็น eigenvector

- เมื่อ $\lambda = \frac{35 - \sqrt{565}}{5}$ จะได้

$$\begin{bmatrix} 8.8 - \frac{35-\sqrt{565}}{5} & 4.4 \\ 4.4 & 5.2 - \frac{35-\sqrt{565}}{5} \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

จะได้ชุดสมการ

$$\left(8.8 - \frac{35 - \sqrt{565}}{5}\right) v_1 + 4.4 v_2 = 0$$

$$4.4 v_1 + \left(5.2 - \frac{35 - \sqrt{565}}{5}\right) v_2 = 0$$

หรือ

$$(9 + \sqrt{565}) v_1 + 22 v_2 = 0$$

$$22 v_1 + (-9 + \sqrt{565}) v_2 = 0$$

ถ้าคูณสมการล่างด้วยสมการทั้งสองชุดนี้เมื่อจัดรูปจะได้สมการเดียวกัน คือ

$$(9 + \sqrt{565}) v_1 + 22 v_2 = 0$$

หนึ่งในคำตอบที่ทำให้ v_1 และ v_2 เป็นจริงคือ

$$v_1 = 22$$

$$v_2 = 9 + \sqrt{565}$$

นั่นคือถ้า $\lambda = \frac{35-\sqrt{565}}{5} = 2.24605427$ จะได้ eigenvector เป็น

$$\hat{v} = \begin{bmatrix} -22 \\ 9 + \sqrt{565} \end{bmatrix}$$

ถ้า normalize ให้มีขนาดเป็นหนึ่ง โดยการหารด้วยขนาดของเวกเตอร์จะได้

$$\mathbf{v} = \begin{bmatrix} -\frac{22}{\sqrt{1130+18\sqrt{565}}} \\ \frac{9+\sqrt{565}}{\sqrt{1130+18\sqrt{565}}} \end{bmatrix} = \begin{bmatrix} -0.5573899686 \\ 0.8302508192 \end{bmatrix}$$

- เมื่อ $\lambda = \frac{35+\sqrt{565}}{5} = 11.75394573$ จะได้

$$\begin{bmatrix} 8.8 - \frac{35+\sqrt{565}}{5} & 4.4 \\ 4.4 & 5.2 - \frac{35+\sqrt{565}}{5} \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

เมื่อจัดรูปจะได้สมการ

$$(9 - \sqrt{565})v_1 + 22v_2 = 0$$

$$22v_1 - (9 + \sqrt{565})v_2 = 0$$

สมการสองสมการนี้เป็นสมการเดียวกัน eigenvector ที่เป็นไปได้คือ

$$\mathbf{v} = \begin{bmatrix} 9 + \sqrt{565} \\ 22 \end{bmatrix}$$

เมื่อ normalize จะได้

$$\mathbf{v} = \begin{bmatrix} \frac{9 + \sqrt{565}}{\sqrt{1130 + 18\sqrt{565}}} \\ \frac{22}{\sqrt{1130 + 18\sqrt{565}}} \end{bmatrix} = \begin{bmatrix} 0.8302508192 \\ 0.5573899686 \end{bmatrix}$$

สรุปคือ eigenvector ที่สอดคล้องกับ eigenvalue คือ

- ถ้า $\lambda = 2.24605427$ จะได้

$$\mathbf{v} = \begin{bmatrix} -0.5573899686 \\ 0.8302508192 \end{bmatrix}$$

- ถ้า $\lambda = 11.75394573$ จะได้

$$\mathbf{v} = \begin{bmatrix} 0.8302508192 \\ 0.5573899686 \end{bmatrix}$$

Eigenvector จะเป็นเวกเตอร์ที่มีทิศทางกับ principal component และถ้าต้องการจะดูว่า principal component ไหนที่เมื่อโปรเจกต์ข้อมูลลงมาแล้วจะให้ค่า variance มากที่สุดให้ดูที่ค่า eigenvalue ที่สอดคล้องกับ eigenvector นั้น ถ้า eigenvalue มีค่ามากแปลว่า variance ของข้อมูลที่โปรเจกต์ลงบน eigenvector นั้นจะยิ่งมีค่ามาก และยิ่งมีความสำคัญอย่างมาก ส่วนแกนที่ค่า eigenvalue มีค่าน้อยหมายความว่าข้อมูลที่โปรเจกต์ลงบนแกนนั้นมีค่า variance น้อย ซึ่งอาจจะได้มีนัยสำคัญและสามารถที่จะไม่นำมาพิจารณาได้




Figure 5: eigenvector และ eigenvector ของข้อมูลตัวอย่างชุดนี้

เมทริกซ์ที่นำมาใช้ในการแปลงระบบพิกัดจะหาได้โดยนำ eigenvector มาต่อกันโดยเรียงจาก eigenvector ที่มี eigenvalue ที่มีค่ามากที่สุดไปหาน้อยสุด

$$V = \begin{bmatrix} 0.8302508192 & -0.5573899686 \\ 0.5573899686 & 0.8302508192 \end{bmatrix}$$

ถ้าต้องการจะแปลงข้อมูลให้อยู่บนพิกัดของ principal component ทำได้โดยคูณกับข้อมูล

$$\begin{aligned} X' &= \begin{bmatrix} -2.2 & -1.6 \\ -0.2 & 1.4 \\ 1.8 & 0.4 \\ -0.2 & -0.6 \\ 0.8 & 0.4 \end{bmatrix} \begin{bmatrix} 0.8302508192 & -0.5573899686 \\ 0.5573899686 & 0.8302508192 \end{bmatrix} \\ &= \begin{bmatrix} 2.71837575 & -0.10214338 \\ 0.61429579 & 1.27382914 \\ 1.71740746 & -0.67120162 \\ -0.50048415 & -0.3866725 \\ 0.88715664 & -0.11381165 \end{bmatrix} \end{aligned}$$

ถ้าต้องการลดจำนวนมิติของข้อมูลก็ตัดหลักท้ายๆ ที่มีค่า eigenvalue น้อยๆทิ้งจนเหลือจำนวนหลักเท่ากับจำนวนมิติที่ต้องการ เช่นถ้าต้องการจะแปลงให้เหลือมิติเดียว

$$X' = \begin{bmatrix} -2.2 & -1.6 \\ -0.2 & 1.4 \\ 1.8 & 0.4 \\ -0.2 & -0.6 \\ 0.8 & 0.4 \end{bmatrix} \begin{bmatrix} 0.8302508192 \\ 0.5573899686 \end{bmatrix}$$

$$= \begin{bmatrix} 2.71837575 \\ 0.61429579 \\ 1.71740746 \\ -0.50048415 \\ 0.88715664 \end{bmatrix}$$

ขั้นตอน PCA

1. standardize ข้อมูล: เลื่อนข้อมูลให้มาอยู่ตรงกลางและทำให้ความแปรปรวนของแต่ละหลักเป็น 1

$$Z = (X - \text{np.mean}(X, \text{axis}=0))/\text{np.std}(X, \text{axis}=0)$$

2. คำนวณหา covariance matrix

$$S = \text{np.dot}(\text{np.transpose}(Z), Z)$$

3. หา eigenvalue และ eigenvector

$$\text{eigenvalue}, \text{eigenvector} = \text{np.linalg.eig}(S)$$

4. เรียง eigenvalue และ eigenvector ตามขนาดของ eigenvalue จากมากไปน้อย

$$\begin{aligned} \text{sorted_idx} &= \text{np.argsort}(\text{eigenvalue})[::-1] \\ \text{eigenvalue} &= \text{eigenvalue}[\text{sorted_idx}] \\ \text{eigenvector} &= \text{np.transpose}(\text{np.transpose}(\text{eigenvector})[\text{sorted_idx}]) \end{aligned}$$

5. สามารถเอา eigenvector ไปใช้ได้ตามต้องการ เช่นถ้าต้องการจะโปรเจกต์ข้อมูลลงบนระนาบ 2มิติ ก็จะได้

$$\text{new_Z} = \text{np.dot}(\text{new_standardized_data}, \text{eigenvector[:, :2]})$$